

Drugi domaći zadatak iz astrostatistike

Za početak, potrebno je prikupiti skup podataka o egzoplanetama, koristeći TAP (*Table Access Protocol*) interfejs. Podaci se dobijaju direktno sa *NASA Exoplanet Archive*.

```
1 import io, requests, pandas as pd
2
3 TAP_URL = "https://exoplanetarchive.ipac.caltech.edu/TAP/sync"
4
5 query = '''
6 SELECT # obrisati komentare prije pokretanja
7     pl_orbper, # orbitalni period [dan]
8     pl_rade, # planetski radijus [Z. radijus]
9     pl_eqt, # rav. temperatura
10    st_met, # zvez. metalicnost
11    discoverymethod
12 FROM pscomppars
13 '''
14
15 r = requests.get(TAP_URL, params={"query": query, "format": "csv"},
16                 timeout=120)
17 exo = pd.read_csv(io.StringIO(r.text))
18 exo.head()
```

Dalje, moguće je definisati klasu tzv. vrućih Jupitera koristeći se sljedećim rezonovanjem:

$$VJ = \begin{cases} 1, & \text{ako } P < 10 \text{ dana i } R_p > 8R_{\oplus}, \\ 0, & \text{inače,} \end{cases}$$

gdje je P orbitalni period, a R_p planetski radijus.

[0.5p] Naći udio vrućih Jupitera u prikupljenom skupu podataka (rezultat prikazati u procentima).

[0.5p] Zvezdana metaličnost $[Fe/H]$ je važan faktor u predviđanju formiranja džinovskih planeta. Pokazati da zvijezde sa $[Fe/H] > 0.4$ imaju značajno veći udio vrućih Jupitera u odnosu na cijeli uzorak.

[3.0p] Koristeći se istim ovim uzorkom ($[Fe/H] > 0.4$), primijeniti *bootstrap* metodu za procjenu neodređenosti uzoračke srednje vrijednosti $\bar{x}$ i uzoračke standardne devijacije s za zvjezdanu metaličnost. Uporediti dobijene raspodjele sa analitičkim izrazima:

$$\sigma_{\bar{x}} = \frac{s}{\sqrt{N}}, \quad \sigma_s = \frac{s}{\sqrt{2(N-1)}}.$$

Prikazati pripadajuće grafike i diskutovati: da li je pretpostavka normalnosti jednako opravdana za $\bar{x}$ i za s ? Da li bi rezultati *jackknife* metode bili bolji od *bootstrap* metode?

Pretpostavimo da je neki skup podataka generisan iz kombinacije konačnog broja normalnih raspodjela sa nepoznatim parametrima - ovo je tzv. *Gaussian mixture model* (GMM). Za mješavinu M normalnih raspodjela, može se pisati:

$$p(x_i, \vec{\theta}) = \sum_{j=1}^M \alpha_j \mathcal{N}(\mu_j, \sigma_j),$$

gdje oteženjenosti zadovoljavaju jednakost $\sum_{j=1}^M \alpha_j = 1$. Dolazimo do poznatog zapisa:

$$\ln L = \sum_{i=1}^N \ln \left[\sum_{j=1}^M \alpha_j \mathcal{N}(\mu_j, \sigma_j) \right] \implies \frac{\partial \ln L}{\partial \mu_j} = \frac{\partial \ln L}{\partial \sigma_j} = \frac{\partial \ln L}{\partial \alpha_j} = 0$$

Nama je ovaj problem poznat od ranije, ali sada je kompleksniji (postoji $k = 3M - 1$ nelinearnih jednačina), te se rješava algoritmom maksimizacije očekivanja (eng. *Expectation maximization algorithm*¹), koji daje rješenje za fiksno M . Sada, nas zanima samo odabir M . Toj svrsi može poslužiti Akaike informacijski kriterijum:

$$\text{AIC} = -2 \ln L^0(M) + 2k + \frac{2k(k+1)}{N-k-1},$$

gdje je L^0 naravno maksimalna vrijednost funkcije *vjerodostojnosti*.

```
1 import numpy as np
2 from sklearn.mixture import GaussianMixture as GM
3
4 # instalacija:
5 # pip install -U scikit-learn
6 # conda install -c conda-forge scikit-learn
7
8 rs = np.random.RandomState(seed=1)
9
10 X = np.concatenate([rs.normal(-1, 1.5, 350),
11                     rs.normal(0, 1, 500),
12                     rs.normal(3, 0.5, 150)]).reshape(-1, 1)
13
14 N = np.arange(1, 11)
15 modeli = [None for i in range(len(N))]
```

¹Više se može pročitati na linku https://www.lri.fr/~sebag/COURS/EM_algorithm.pdf.

```

16
17 for i in range(len(N)):
18     modeli[i] = GM(N[i]).fit(X)
19
20 AIC = [m.aic(X) for m in modeli]
21
22 najbolje_N = N[np.argmin(AIC)]
23 najbolji_model = modeli[np.argmin(AIC)]
24 print(najbolje_N, najbolji_model)
25
26 plt.plot(N, AIC)
27 plt.xlabel('$M$')
28 plt.ylabel('$AIC$')
29 plt.show()

```

[3.0p] Iznad je dat primjer nalaženja AIC u slučaju mješavine tri normalne raspodjele. Sličnu proceduru treba primijeniti na raspodjeli R_p . Koristeći GMM i AIC odrediti optimalan broj komponenti M i prikazati fitovane raspodjele. Interpretirati rezultat. Zatim proceduru odraditi samo za `discoverymethod == 'Transit'`. Trebalo bi da se u oba slučaja uočavaju neke *praznine*.²

[0.5p] Naći planetu čije je T_{eq} najbliže $T_{eq,\oplus}$. Za nju: ispisati broj zvijezda u tom sistemu, broj planeta u sistemu, teleskop kojim je planeta otkrivena, masu planete ($m_{\oplus}$) i ekscentričnost njene orbite. Biće potrebno uraditi novi *query*.

[2.5p] Koristeći ravnotežnu temperaturu planeta T_{eq} , konstruisati empirijsku kumulativnu raspodjelu (ECDF). Primijeniti metodu inverznog uzorkovanja - generisati $N_{syn} = 10^3$ uzoraka iz uniformne raspodjele $\mathcal{U}(0, 1)$ i inverznim mapiranjem preko ECDF dobiti sintetičke vrijednosti T_{eq} . Uporediti raspodjelu sintetičkih uzoraka sa originalnom (preko histograma). Da li se ova metoda suštinski razlikuje od npr. *bootstrap* metode? Ako da, kako? Koju raspodjelu biste fitovali na T_{eq} i zašto?

Uputstvo za rješenje: svaku liniju koda je potrebno zakomentarisati i treba detaljno objasniti postupak rješavanja. Na svakom grafiku treba staviti nazive osa, relevantne naslove itd.

²Vidjeti npr. <https://arxiv.org/abs/1703.10375>.